

JTORA: 把长期随机约束折成单时隙决策的 UAV-MEC 联合优化


Joint Trajectory Optimization and Resource Allocation in UAV-MEC Systems: A Lyapunov-Assisted DRL Approach

Lyapunov 辅助 DRL 的轨迹与资源联合优化

Chen, Yang, Wu, Huang, Zhao | IEEE Transactions on Services Computing, vol.18, no.2, pp.854–866, 2025 | 汇报人: <yuan fei> | 2026-09-19

- ❏ 这篇论文研究的是 UAV-MEC 场景下的轨迹与资源联合优化——它在“用户随机移动 + 任务随机到达 + UAV 长期续航约束”都不确定、且无法预知未来的前提下，用 Lyapunov 漂移加罚把长期随机优化压成单时隙确定性优化，再把三个决策变量拆成“解析解（CPU 频率、卸载功率）+ SAC 学轨迹”，论文通过理论分析与仿真验证能耗—队列折中，但实际在线推理时延及学习误差界未作实测/完整证明。

真正的缺口不是“资源分配”，而是“UAV 与用户同时移动”



核心难点不是单纯的资源分配，而是 UAV 和地面用户同时移动。用户一方面有随机任务到达，另一方面按照 Gauss-Markov 模型移动；UAV 既要服务用户，又要满足飞行能耗和返航要求。

任务场景：

- 一架固定高度 100 米的无人机，机载边缘服务器，服务默认 5 个地面用户。
- 用户侧两件事同时发生：任务按泊松到达进先进先出队列；用户按 Gauss-Markov 模型随机移动。无人机侧两个约束：起点出发，服务结束飞回补能点；每时隙平均推进能耗不超过 155 焦耳。
- 用户的每条任务走两条并行支路：本地计算，控制 CPU 频率 f ；部分卸载，控制卸载功率 P ，用 FDMA（频分多址）把带宽平均切成 I 份。
- 关键耦合点：无人机位置 p_u 同时出现在两个地方——信道增益和自身推进能耗。位置决定信道，信道决定卸载速率，因此轨迹与卸载功率不能分开优化。

现有工作多数只让一侧移动（UAV 或用户），或忽略“随机到达”与“移动”的共存

已有数学方法在高维轨迹问题上复杂度高、响应慢

纯 DRL 直解会导致状态/动作空间爆炸，且难以保证长期约束可行

在上述场景中，由于轨迹与卸载功率通过信道增益强耦合（通信链路采用概率 LoS 模型，并基于 UAV 与用户的相对位置决定传输速率，因此 UAV 轨迹会直接影响卸载收益），系统难以在 UAV 续航受限与任务队列稳定的前提下最小化 MU 能耗。

上述耦合动机推动作者采用“Lyapunov + 解析优化 + SAC”的混合求解框架。一个合理的问题表述不是“优化轨迹”本身，而是“如何让长期约束、连续控制和结构化资源分配共存”。

三个决策变量、一个长期目标、三条关键约束

长期目标（P1）：最小化MU的长期平均能耗（本地计算 + 卸载）

$$P1 : \min_{\varphi[n]} \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N \sum_{i=1}^I E_i[n]$$

其中 $E_i[n] = \gamma_c f_i[n]^3 \Delta + \Delta P_i[n]$, $\varphi[n] = \{f_i[n], P_i[n], p_u[n]\}$

决策变量	控制的是什么	约束
$f_i[n]$ （CPU 频率）	MU 每时隙本地处理的比特数 $D_i^l = f_i \Delta / C_i$	$0 \leq f_i \leq 1 \times 10^9 \text{ Hz}$; $D_i^l + D_i^u \leq Q_i + A_i$
$P_i[n]$ （卸载功率）	经信道上行的比特数 $D_i^u = \Delta \cdot R_i$, R_i 由香农公式给出	$0 \leq P_i \leq 0.1 \text{ W}$
$p_u[n]$ （UAV 位置）	决定信道增益与推进能耗，间接决定能耗大小	起点 $p_u[1]$ 、终点 p_F ；每时隙位移 $\leq v_{\max} \Delta$ ；剩余时隙必须能飞回 p_F


需满足的三个关键长期约束

(16b) UAV 推进能耗的长期平均上界 （用虚拟队列 $U[n]$ 表达， $E_u=155 \text{ J/时隙}$ ） $\rightarrow$ 保证续航	(16c) MU 任务队列长期稳定 $\lim \frac{1}{N} \sum E\{Q_i[n]\} < \infty$	(16f) 单时隙“处理量 $\leq$ 积压量 + 到达量”（ $D_i^l + D_i^u \leq Q_i + A_i$ ），不允许无中生有地处理超过可用量的任务
--	---	--

一个很重要的直觉：作者不是简单地“让每个时隙的能耗最小”，而是在长期范围内考虑“省能耗”和“不能让队列爆掉”之间的平衡。

决策时标：单时隙（ $\Delta=1 \text{ s}$ ）在线决策，全周期 N 个时隙的多阶段随机优化。

从显式决策变量看，本文展示出的主要困难似乎并非整数决策，而是长期随机约束与非凸耦合



真正的困难是三条叠加：

1. 未来信息不可预知，是随机动态优化；
2. 速率项与推进功率项非凸；
3. 位置同时进入信道与能耗，轨迹与资源强耦合。

❏ 论文将问题称为混合整数非线性规划MINLP，但从正文显式列出的决策变量看，未看到明显的整数/二元决策变量，本文的三个决策变量 f 、 P 、 p_u 实际上都是连续变量（论文用“按比例缩放 CPU 频率与卸载功率”替代二元卸载）。因此‘Mixed-Integer’这一表述值得商榷；本文实际展示出来的核心难点更像是长期随机约束下的非凸耦合优化。

长期约束进队列，可解析变量进闭式解，非凸轨迹交给 SAC

第一层：Lyapunov 漂移加罚（长期 → 单时隙）

$$D(Q[n]) = \Delta L(Q[n]) + V \mathbb{E}\{E[n] \mid Q[n]\}, \quad E[n] = \sum_{i=1}^I E_i[n], \quad V > 0$$

其中 $Q[n]$ 包含用户任务队列和 UAV 的虚拟能量队列， $E[n]$ 是MU的总能耗,；UAV 虚拟能量队列（Virtual Energy Queue） 定义为：

$$U[n+1] = \max \{U[n] + E_v[n] - E_u, 0\}$$

- $U[n]$ ：第 n 个时隙的 **UAV虚拟能量队列**
- $E_v[n]$ ：第 n 个时隙 UAV 的**实际能耗**（主要与飞行推进能耗有关）
- E_u ：每个时隙对应的**平均能量预算**
- $\max\{\cdot, 0\}$ ：保证虚拟队列不会小于 0
- 把原本跨时间的长期平均能耗约束转化成每个时隙都可以处理的队列稳定性问题。UAV 某个时隙能耗超过平均预算时，虚拟队列就会增长，从而在后续决策中增加对能耗的惩罚。

作者把用户队列和 UAV 的虚拟能量队列放进 Lyapunov function。然后把“长期约束”和“能耗目标”组合成 drift-plus-penalty，并进一步优化它的一个上界。结果是长期约束由虚拟队列吸收到单时隙目标中，用户队列与无人机能量队列变成上界表达式里的系数，问题化为每时隙只需满足单时隙约束的确定性问题 P2：

$$\min_{\varphi[n]} U[n] P_{\text{UAV}}(v[n]) \Delta - \sum_{i=1}^I Q_i[n] \left(\frac{f_i[n] \Delta}{C_i} + \Delta R_i[n] \right) + V \sum_{i=1}^I (\gamma_c f_i[n]^3 \Delta + \Delta P_i[n]), \quad \text{s.t. (16d)-(16i)}$$

第二层：按变量可解性再拆

P3-1（只含 f_i ） → CPU 频率 f 与另外两个变量不耦合，且只含 f 的部分是三次函数，凸 → 解析解（式 28）


P3-2（含 P_i 与 p_u ） → 非凸 → 先固定 p_u ：给定信道 g_i ，P3-2' 对 P_i 是一维非线性规划 → 卸载功率解析解（式 37）；再让 SAC 学 p_u

两处反馈

Lyapunov 侧把用户任务队列 $Q_i[n]$ 、Lyapunov 虚拟能量队列 $U[n]$ 送给 SAC 作为状态与奖励权重
SAC 侧把位置 $p_u[n]$ 送回，结算信道增益与推进能耗，回填奖励。

拆分的代价与收益

Lyapunov 提供长期优化的理论框架；实际 SAC 采用近似学习策略，因此其与理想每时隙最优解之间的误差需要单独考虑，换来每时隙 $O(I + \sum n_{i-1} n_i)$ 的在线复杂度与长期约束的可行性



Algorithm 1：时隙级执行流程

- ① **更新 Lyapunov 队列状态**
根据当前任务队列与能量虚拟队列构造时隙决策状态。
- ② **CPU 频率解析求解**
 $f_i^*[n] \leftarrow \text{Eq.}(28)$
- ③ **SAC 生成 UAV 轨迹动作**
 $\mathbf{a}[n] = (v[n], \theta[n]) \Rightarrow p_u[n]$
- ④ **给定位置解析求解卸载功率**
 $P_i^*[n] \leftarrow \text{Eq.}(37)$
- ⑤ **联合决策输出**
 $\phi[n] = \{f_i[n], P_i[n], p_u[n]\}$

系统架构：算法各模块的职责

模块	方法类别	解决哪个子问题	输入 → 输出	可行性保障
漂移加罚	Lyapunov 随机优化	把长期随机问题变单时隙确定性	用户队列长度 $Q[n]$ 、UAV虚拟能量队列 $U[n]$ 、用户的任务到达量 $A_i[n] \rightarrow P_2$ 的目标权重	将长期平均约束转化为虚拟队列稳定性条件
P3-1	凸优化（解析）	MU 本地计算频率	用户任务队列长度 $Q_i[n] \rightarrow$ 用户最优CPU频率 $f_i^*[n]$	解析解自动满足 $0 \leq f \leq f_{\max}$ 与队列容量约束
P3-2'	非线性规划（一维求导）	MU 卸载功率	给定 信道增益 $g_i[n] \rightarrow$ 用户最优卸载功率 $P_i^*[n]$	取 $\min\{P_{\max}, \dots\}$; $V \leq G[n]$ 时回落到 0
轨迹	深度强化学习（SAC，单智能体）	非凸连续 UAV 位置 $p_u[n]$	状态 $(A_i, Q_i, c_i, c_u, V_u, U) \rightarrow$ 动作 $(v[n], \theta[n])$	通过起点/终点/速度约束与奖励设计间接约束，从论文给出的机制来看无投影或掩码机制

时间线定位：数学规划/博弈论 → 组合与元启发式 → 分布式优化 → DRL（DDPG/PPO/SAC） → 学习与优化混合（本文：**Lyapunov 保证可行性 + CPU 频率→解析；UAV 轨迹→SAC；卸载功率→给定轨迹后的解析解**）。

复杂度：单时隙单时隙仅需 $O(I)$ 解析资源分配 + 一次 SAC Policy Forward Pass；完整 T 时隙复杂度为 $O(I + \sum_{l=1}^L n_{l-1}n_l)$ ；在线阶段避免 SCA/DAI 的数值迭代；训练阶段仍存在 SAC 迭代训练成本

实验设置与证据边界：仿真验证为主

平台：Python 3.8.10 + PyTorch 1.10.0，Intel i7-13650HX + NVIDIA RTX 4070Ti，自建仿真器（无真实飞行、无硬件在环）

关键参数（p.863）

参数	取值	参数
场景范围	500 m × 500 m	时隙长度 Δ ：1 s
MU 数 I	5（规模实验到 25）	UAV 高度 H：100 m
最大到达率 A_max	2×10^6 bit/s（Poisson, $\lambda=10$ ）	UAV 最大速度 v_max：5 m/s
MU 最大 CPU 频率 f_max	1×10^9 Hz	UAV 每时隙平均能耗上限 E_u：155 J
MU 最大卸载功率 P_max	0.1 W	环境噪声功率 N_0： 1×10^{-12}
每比特所需 CPU 周期 C_i	1000	带宽 W_u：1 MHz
能耗系数 γ_c	1×10^{-27}	折中因子 V： 5×10^{12}

SAC 超参：策略网络 MLP(256,128)，两个软 Q 网络 MLP(128,64,1)，Adam， $\tau=0.05$ ， $\alpha=0.5$ ， $lr=1\times10^{-4}$ ， $\gamma=0.99$ ，5000 回合 × 600 步；经验池 30000（最优），batch 512（优于 256）。

基线：LyDROO 为 Lyapunov 加 DRL 的二元卸载，因其不考虑用户移动，实验配了朝用户中心飞的贪心；JRATO 为长短时隙混合、Stackelberg 博弈加对偶优化；Random；SAC 换成 PPO 的 Ly-PPO。

主张—证据对照表

论文主张	对应实验	指标	是否充分	还缺什么
长期约束可在线满足	Fig. 8/9	MU 能耗、队列长度	部分	缺 UAV 能量队列 U[n] 曲线，续航结论无实测
轨迹优化有独立贡献	Fig. 4/5、Random 基线	轨迹形态、能耗	部分	缺严格消融与多次随机种子
优于现有方法	Fig. 12/13	能耗、队列	是	无耗时、无 P95/P99 时延、无方差

机制可信、规模近似线性，但鲁棒性与尾部指标完全缺失





Fig. 3. The energy consumption and queue length with the different values of V .

(a) Fig. 3 | 权衡参数V的影响验证


随着 V 增大，系统以更高的队列积压为代价降低能耗： $V \uparrow \rightarrow$ 能耗 $\downarrow$ ； $V \uparrow \rightarrow$ Queue backlog $\uparrow$ ；
验证了 Lyapunov 中能耗与队列长度的权衡关系。后续实验取 $V = 5 \times 10^{12}$



(a) The UAV starting from (50, 50) (b) The UAV starting from (250, 450)
(c) The UAV starting from (50, 450) (d) The MU 1 with more task backlog


(b) Fig. 4(a) vs 4(d) | 机制验证

UAV 从不同起点出发都能先奔向 MU 轨迹、结束后返回 (500,0)；把 MU1 的到达率提到 2.5 倍后，轨迹整体下移靠近 MU1 $\rightarrow$ 与 reward 中的 queue-backlog 项作用相一致



(c) Fig. 6/7 | 收敛性验证

经验池 30000 收敛最快；batch 256 的收敛时间是 512 的三倍 $\rightarrow$ 训练对超参较敏感，且只报告平滑奖励曲线，无成功率与方差



(d) Fig. 10/11 | 规模扩展性验证

MU 从 5 增到 25，总能耗从 0.133 线性升到 0.66，队列同步上升 $\rightarrow$ 单用户平均能耗几乎不变 (0.0266 $\rightarrow$ 0.0264)，表明 JTORA 在测试的 5-25 MU 范围内表现出近似线性扩展趋势，并保持高效的能源管理

❏ 机制实验较充分，但没有鲁棒性实验（CSI/位置误差、到达率突变）、没有尾部指标（P95/P99 时延、超时率、失败率）、没有计算开销实测。

最终性能对比：联合考察 MU 能耗与任务队列




Fig. 12（比较不同算法降低 MU 能耗的效果）与 **Fig. 13**（比较不同算法维持任务队列稳定的能力）

横轴 0–1000 时隙；Fig. 12 纵轴为 MU 能耗；Fig. 13 纵轴为队列长度（量级 10^7 bit）。

核心趋势

除 Random 外所有算法都收敛到平稳态；JTORA 能耗约 0.155，依次是 Ly-PPO $\approx$ 0.205、JRATO $\approx$ 0.25、LyDROO $\approx$ 0.37，Random 持续升到 1.36。在所比较的 baseline 中，JTORA 同时取得最低 MU 能耗和较好的队列稳定性

原因解释

JTORA 用 SAC 学轨迹而非贪心（LyDROO 用指向 MU 中心点的贪心，稳定队列方面非常有效但省能耗效果差）；JRATO 用 Lagrangian 对偶 + 交替优化，能耗尚可但队列控制不足；Random 只靠 Lyapunov 分配资源、轨迹随机，在用户移动下队列失控

主张对应

支撑“JTORA 同时兼顾 MU 能耗降低与任务队列稳定”的核心主张

证据边界

只有 1000 时隙、单次运行，未报告随机种子与方差；没有训练与推理耗时，“在线快速响应”只有复杂度分析支撑

值得学的是"拆分方式", 不足在于证据链与可复现性

作者结论: 本文方法能够降低 MU 能耗、改善队列稳定; 未来工作: MADRL + Lyapunov + multi-UAV"

✓ 值得学

贡献:

- 对不同子问题采用不同求解工具。把长期随机约束与可解析变量从 RL 手里剥离出来——Lyapunov 管可行性、闭式解管 f 与 P 、SAC 只管最难的非凸连续轨迹。这个"分工设计"是可迁移的方法论。

可迁移启发:

- 把"长期约束 → 虚拟队列 → 单时隙确定性优化 → 可解析变量剥离 → 只把非凸部分交给 RL"这套模板进行运用; 指标上必须补尾部时延、超时率、平台剩余能量与在线耗时。

Related Work写作素材:

- 与只做资源分配的工作相比, 本文把 UAV 轨迹真正拉进主问题, 而不是视为外生变量。
- 与只做轨迹优化的工作相比, 本文同时处理通信资源与计算资源, 因此系统耦合度更高。
- 与纯 DRL 路线相比, 本文保留了凸优化对结构化变量的解析能力; 与纯 Lyapunov 路线相比, 它又引入了 SAC 来应对复杂连续状态控制。

⚠ 需要质疑

- Table I 缺失关键信道参数 (g_0 、 κ 、 a 、 b 、 $\bar{l}$ 、 μ_1/μ_2), 论文不可完全复现
- Fig. 12/13 仅单次运行、无随机种子与方差报告
- 无训练/推理耗时实测, "在线快速响应"仅有复杂度分析支撑, 仅论证了 JTORA 具有在线快速决策的机制基础
- 无鲁棒性实验 (CSI/位置误差、到达率突变) 与尾部指标 (P_{95}/P_{99} 时延、超时率、失败率)
- 核心的无人机续航约束没有任何验证曲线

系统建模

① 移动用户与无线信道

- I 个移动用户（MU）+ 1 架 UAV，采用离散时隙 n
- $\mathbf{p}_i[n]$ ：用户 i 的二维位置； $\mathbf{p}_u[n]$ ：UAV 位置
- 用户移动服从 **Gauss–Markov 模型**
- UAV–MU 距离决定 LoS/NLoS 与信道增益 $g_i[n]$

$$R_i[n] = \frac{W_u}{I} \log_2 \left(1 + \frac{g_i[n]P_i[n]}{N_0[n]} \right)$$

$P_i[n]$ ：用户 i 的卸载发射功率； $R_i[n]$ ：卸载速率

② 任务队列与用户能耗

- $A_i[n]$ ：时隙 n 用户 i 新到达的任务量
- $Q_i[n]$ ：时隙 n 用户 i 当前任务队列长度
- 任务可本地计算，也可卸载至 UAV

$$D_i^l[n] = \frac{f_i[n]\Delta}{C_i}, \quad D_i^u[n] = R_i[n]\Delta$$

$$Q_i[n+1] = \max\{Q_i[n] + A_i[n] - D_i^l[n] - D_i^u[n], 0\}$$

$f_i[n]$ ：用户 CPU 频率； D_i^l, D_i^u ：本地/卸载处理任务量

- 用户能耗：

$$E_i[n] = \gamma_c f_i^3[n]\Delta + P_i[n]\Delta$$

③ UAV 能量与长期约束

- $E_v[n]$ ：UAV 时隙 nn 的飞行能耗
- $U[n]$ ：UAV 虚拟能量队列，用于刻画长期平均能量约束

$$U[n+1] = \max\{U[n] + E_v[n] - E_u, 0\}$$

- $Q_i[n] \rightarrow$ 保证用户任务队列长期稳定
- $U[n] \rightarrow$ 处理 UAV 长期平均能量约束

Q1: SAC 是否拥有足够的状态信息来做可行且合理的轨迹决策?

- 从决策信息角度看，论文给出的 state 已经包含任务到达、队列、MU/UAV 位置、UAV 速度和虚拟能量队列，因此能够支持基于负载和空间关系的轨迹决策；但从严格的 MDP 和约束可行性角度看，论文论证并不充分。特别是 Gauss–Markov 用户运动依赖 MU 速度，而式(30)没有显式包含 MU 速度；同时剩余真实电池、返航可达性以及动作约束如何在 SAC 中保证也没有完整说明。因此更准确地说，它的 state 对‘合理轨迹决策’基本覆盖，但对‘严格 Markov 性和可行性保证’仍存在证据缺口。

Q2: 闭式 f_i^* 和 P_i^* 有没有真正考虑这个总任务量约束 $D_i^u \leq Q_i + A_i - D_i^l$?

- f_i^* 对本地处理量施加了 $Q_i + A_i$ 上限，但 P_i^* 的闭式解未显式体现剩余任务约束 $D_i^u \leq Q_i + A_i - D_i^l$ ；需结合 Algorithm 1 的顺序更新进一步核对联合可行性。在算法1中的描述是：先求 CPU 频率并更新 Q ，再生成轨迹和求卸载功率，然后再次更新 Q 。如果第二步的 P_i^* 真的是基于： $Q' = Q + A - D_i^l$ ，计算，那么它就有机会间接满足剩余任务约束。

Q3: Lyapunov 分解后，是否保留了本地计算与卸载的任务量耦合约束?

- 同Q2

Q4:理论性能界如何对应实际 SAC 策略与求解误差?

- 论文的 Theorem 2 给出了 Z/V 形式的理论性能界，但这个分析是基于理想的最优决策来建立的。实际 JTORA 的轨迹由 SAC 近似求解，因此实际策略与理想每时隙最优解之间存在学习误差。论文没有进一步给出 SAC 的统一近似误差界，所以严格来说， Z/V 不能直接理解成实际 SAC 策略的精确性能保证。因此实际应该存在一个 SAC/数值求解误差，例如抽象写成 $\epsilon[n] = J_{\text{SAC}}[n] - J^*[n]$ 。那么实际性能应当理解为：理论Lyapunov误差 + SAC近似求解误差